

Automatisation des politiques métier avec LLMs


Groupe 7

*Romain Grivaud, Titouan Brunel, Claudia Agromayor,
Omar Amari, Ahmed Dargouthy*

SOMMAIRE

Contexte: le problème	3
Architecture du projet	4
Démarche scientifique	9
Comparaison et analyse	18
Conclusion	22
Bibliographie	24

Le problème : implémenter des politiques métiers



Architecture des données : input

travel_class	age_category	luggages
{ Economy, Business, First }	{ infant, child, adult }	<pre>{{"storage": {"personal", "carry-on", "checked"}, "weight": 5.22, "height": 61.58, "width": 12.63, "depth": 18.76, "unit": "cm"}, {autres bagages}}</pre>

Architecture des données : output


compliance	compliance_message	cargo_items	fees
{ True, False}	{ 'All luggage complies with the policy', "Carry-on: Total weight 14.23kg exceeds 12kg limit, all carry-on items transferred to cargo.", ... }	{{""storage"": {""personal"", ""carry-on"", ""checked""} ""weight"": 5.22, ""height"": 61.58, ""width"": 12.63, ""depth"": 18.76, ""unit"": ""cm""} {autres bagages qui doivent aller en fret}}	{75, 100, 150}i

Incohérences dans les données

Le code de génération s'arrêtait sur la première erreur de compliance → compliance OK

Reformulation de la policy.txt et du generator.py

Pipeline de décision



Prompt architecture

1 Introduction

You are an expert airline baggage compliance analyst with extensive knowledge of aviation regulations and baggage policies.

2 Policy & Réponse type

Analyze each passenger's baggage against the provided policy and determine compliance status, applicable fees, cargo requirements, and provide detailed explanations.

3 Output Format

```
{ "results": [ {  
  "client_id": 1,  
  "compliance_result": true/false,  
  "compliance_message": "detailed explanation",  
  "fees": 0,  
  "cargo_items": [] } ]
```

4 Exemple(s)

5 Client Processing

Process all clients sequentially using their client_id (1, 2, 3...) and provide complete analysis for each passenger.


6 Final instruction

Return ONLY the JSON response with no additional text or formatting.""


Démarche scientifique

BRUTE

BRUTE




Démarche scientifique



ITERATION


1. Analyse un par un les passagers




ITERATION

+ few-shot learning



1. Analyse un par un les passagers
2. Amélioration avec du few-shot learning : 4 exemples fournis dans le prompt




Démarche scientifique



ITERATION ++




Démarche scientifique



RAG

Recherche+Génération

1. Représentations de cas: “fiche” standardisée
2. Vectorisation des données: all-MiniLM-L6-v2 -> TF-IDF
3. Intégration




Métriques

compliance	compliance_message	cargo_items	fees
$Recall = \frac{TP}{TP + FN}$	Reconnaissance de caractères	$Recall = \frac{TP}{TP + FN}$	Exact match
$Precision = \frac{TP}{TP + FP}$	LLM as a judge	$Precision = \frac{TP}{TP + FP}$	$MAE = \frac{1}{N} \sum_{i=1}^N y_i - \hat{y}_i $
$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$		$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$	$RMSE = \sqrt{\frac{\sum_{i=1}^N \ y(i) - \hat{y}(i)\ ^2}{N}}$

LLM as a judge




Model 1



Model 2

Comparaison Précision vs F1-Score



Résultats : fees

	Brute	Iteration	Iteration + FSL	RAG	Iteration ++
Exact match	Na	46 %	45 %	91 %	43%
MAE	Na	69 €	72 €	8 €	100 €
RMSE	Na	111 €	114 €	34 €	167 €

Perspectives d'évolution

Comparaison de différents LLMs

Pour l'instant : **Mistral Large** et Llama 3.2-3B

Calcul de rentabilité économique et environnemental

Test avec ajout d'erreurs dans la requette

Amélioration du retour humain

Pour que le LLM comprenne complètement la
politique.

Bibliographie

Utilisation dans le projet	Description	Auteurs
Automatisation des politiques métiers	Exécute automatiquement des politiques métier à partir d'intents via prompting	Dzeparoska et al., 2023
Few-Shot Learning pour améliorer le raisonnement LLM	Décomposition logique de politiques avec prompts few-shot	Erwin et al., 2025
RAG pour améliorer le Few-Shot Learning	RAG dynamique récupérant des exemples de code pour améliorer les prompts few-shot dans des traductions difficiles	Bhattarai et al., 2024

Questions

Groupe 7

*Romain Grivaud, Titouan Brunel, Claudia Agromayor,
Omar Amari, Ahmed Dargouthy*