



CentraleSupélec

Leveraging LLMs for Business Logic Extraction and Inference

Pôle Intelligence Artificielle

Groupe 7 :

Agromayor Claudia

Amari Omar

Brunel Titouan

Dargouthy Ahmed

Grivaud Romain

Encadré par :

Feillet Pierre

Ouerdane Wassila

Poli Jean-Philippe

2A-CentraleSupélec

2024-2025

Table des matières

1	Introduction	2
1.1	Présentation du client et de l'entreprise	2
1.2	Problème posé et bénéfice attendu par le client	2
2	Etat de l'art	3
2.1	Extraction et formalisation automatisée des règles métier	3
2.2	Intégration des LLMs dans les systèmes décisionnels et explicabilité	3
2.3	Applications sectorielles et gestion des connaissances	3
2.4	Évaluation des LLMs et limites du raisonnement	4
2.5	Few-Shot Learning, décomposition logique et RAG dynamique	4
2.6	Synthèse et lien avec notre projet	4
3	Description du travail réalisé	6
3.1	Correction des incohérences dans les données	6
3.2	Méthode batch	6
3.3	Itératif simple	7
3.4	Itératif FSL	8
3.5	Itératif questions	8
3.6	RAG et approche hybride	9
3.7	MÉTRIQUES DE CONFORMITÉ	10
3.8	MÉTRIQUES D'ESTIMATION DES FRAIS	11
3.9	MÉTRIQUES D'IDENTIFICATION CARGO	11
3.10	MÉTRIQUES DE MESSAGES DE CONFORMITÉ	12
4	Conclusion	14
5	Bibliographie	15

1 Introduction

1.1 Présentation du client et de l'entreprise

Le laboratoire de Recherche et Développement (R&D) d'IBM à Paris-Saclay, également appelé Centre d'Innovation pour l'Intelligence Artificielle, est le principal site de recherche d'IBM en France. Ouvert en 2019, il est implanté au cœur du cluster scientifique et technologique de Paris-Saclay, qui concentre à lui seul 15% de la R&D française, publique et privée. Ce centre stratégique favorise la collaboration entre IBM et de grands acteurs académiques et industriels, stimulant ainsi l'innovation.

Le laboratoire accueille actuellement plus de 200 collaborateurs et peut en recevoir jusqu'à 350. Cette équipe cosmopolite rassemble des chercheurs, développeurs, chefs de produit, designers, data scientists et consultants, représentant une dizaine de nationalités. Leurs travaux s'articulent autour de trois axes majeurs : la prise de décision automatisée, l'automatisation des processus métiers et le développement d'outils pour mainframes.

Notre client, M. Pierre Feillet, architecte chez IBM, est spécialisé dans l'intelligence artificielle symbolique et l'apprentissage automatique appliqués aux décisions algorithmiques. Il dirige un projet qui vise à exploiter les avancées de l'IA générative pour automatiser les décisions d'entreprise. IBM propose déjà plusieurs solutions dans ce domaine, telles qu'IBM Operational Decision Manager (ODM), IBM Automation Decision Services (ADS), IBM watsonx et IBM watsonx Orchestrate, qui forment l'écosystème technologique de référence pour ce projet.

1.2 Problème posé et bénéfice attendu par le client

Le défi principal rencontré par IBM France Lab concerne « la difficulté des LLMs à raisonner de façon autonome, fiable et logique ». En effet, les systèmes d'IA générative actuels, comme les grands modèles de langage (LLM), sont parfois qualifiés de « perroquets stochastiques », car ils s'appuient sur des modèles statistiques plutôt que sur un raisonnement formel authentique. Cette caractéristique soulève des questions majeures quant à leur fiabilité dans des contextes décisionnels, où la précision et le respect des normes sont indispensables.

De plus, la complexité et le coût de l'automatisation des politiques d'entreprise représentent un obstacle important, notamment pour les PME. Extraire des règles métiers à partir de textes non structurés pose de nombreux problèmes : complexité opérationnelle, subjectivité des règles, limites des méthodes d'analyse linguistique, qualité inégale des données et résistance au changement au sein des organisations.

IBM France Lab attend plusieurs bénéfices de ce projet :

- Faciliter l'extraction de connaissances à partir de données non structurées (textes, images) pour construire des modèles formels d'aide à la décision
- Accroître l'efficacité dans la mise en œuvre de l'automatisation
- Simplifier l'adaptation aux évolutions réglementaires et aux changements du marché
- Réduire les coûts opérationnels tout en renforçant la conformité
- Libérer les experts métier pour qu'ils se consacrent à des missions à plus forte valeur ajoutée

La question centrale est donc : « Peut-on faire confiance à un LLM pour prendre une décision et appliquer une politique d'entreprise ? » Cette interrogation est cruciale dans des secteurs où l'automatisation des décisions a un impact majeur, comme l'assurance, la banque, les télécommunications ou les services publics, qui constituent les principaux domaines ciblés par IBM. Les enjeux de fiabilité, d'explicabilité et de conformité réglementaire sont au cœur de cette réflexion, et les solutions qui seront apportées façonneront l'avenir de l'automatisation décisionnelle par l'IA générative.

2 Etat de l'art

L'automatisation des politiques métier à l'aide des grands modèles de langage (LLMs) est aujourd'hui au cœur des stratégies d'innovation des entreprises, qui cherchent à gagner en efficacité, en conformité et en adaptabilité. Les avancées récentes de la recherche explorent l'extraction automatisée de règles métier, l'intégration des LLMs dans les processus décisionnels, l'amélioration de l'explicabilité, l'évaluation des performances, ainsi que le développement de méthodes avancées de raisonnement et d'apprentissage. Nous proposons ici une analyse critique des contributions majeures, en soulignant leur impact direct sur la conception et la mise en œuvre de notre projet.

2.1 Extraction et formalisation automatisée des règles métier

L'un des axes fondateurs de l'état de l'art porte sur l'extraction et la formalisation automatique des règles métier à partir de documents non structurés. Miskell et al. [1] proposent un cadre basé sur le traitement automatique du langage naturel pour extraire exigences logicielles et règles métier depuis le code source et la documentation. Leur méthode identifie et structure les connaissances implicites, facilitant leur exploitation par des systèmes experts. Cette approche inspire directement notre démarche, qui vise à automatiser l'analyse de politiques bagages aériennes à partir de textes réglementaires, en structurant les entrées et sorties pour permettre une prise de décision automatisée et traçable.

Bernardi et al. [3] complètent cette perspective en introduisant les Business Process-aware Large Language Models (BPLLMs), qui associent la génération augmentée par récupération (RAG) à un entraînement spécifique au domaine. Leur approche permet d'enrichir la compréhension des processus métier et de générer des réponses précises et contextualisées, même en présence de règles complexes ou peu fréquentes. Cette méthodologie a inspiré la structuration de notre pipeline, qui adapte dynamiquement le contexte fourni au modèle selon les spécificités des cas traités.

2.2 Intégration des LLMs dans les systèmes décisionnels et explicabilité

L'intégration des LLMs dans les systèmes de décision pose la question cruciale de la confiance et de la transparence. Raikov et al. [2] explorent des modèles hybrides associant LLMs et modules d'intelligence artificielle explicable (XAI), afin de rendre les recommandations générées plus compréhensibles pour les utilisateurs, notamment dans des secteurs réglementés comme la finance ou la santé. Cette exigence de transparence se retrouve dans notre projet à travers la génération de messages de conformité détaillés et l'explicitation des décisions prises par le système.

Ugarte [5] propose une vulgarisation des principes de fonctionnement des LLMs et de leur intégration dans les applications métiers. Il insiste sur l'importance de l'interface entre l'humain et la machine, et la nécessité de concevoir des systèmes capables de justifier leurs décisions de manière claire et accessible. Notre pipeline s'inspire de ces recommandations en privilégiant des retours structurés et argumentés pour chaque cas d'analyse.

2.3 Applications sectorielles et gestion des connaissances

L'apport des LLMs à la prise de décision automatisée est particulièrement mis en lumière dans le secteur financier. L'équipe de doctorants de l'Institut Stevens de technologie [4] montre que l'IA peut assister les gestionnaires financiers en fournissant un traitement rapide et une reconnaissance de motifs, augmentant ainsi la capacité d'analyse des portefeuilles et la réactivité face aux évolutions du marché. Ces résultats confirment la capacité des LLMs à traiter de grands volumes de données, à détecter des motifs complexes et à fournir des analyses en temps réel,

compétences que nous avons mobilisées dans notre projet pour l'analyse de politiques bagages complexes.

Bernardi et al. [3] soulignent également l'intérêt d'intégrer les LLMs dans les systèmes de gestion des connaissances d'entreprise, permettant d'automatiser la création, la recherche et la synthèse de connaissances, tout en personnalisant l'accès à l'information. Cette capacité à extraire et à structurer la connaissance inspire notre démarche d'enrichissement dynamique du contexte, notamment via le RAG, qui permet d'intégrer des exemples pertinents dans le prompt du modèle pour améliorer la pertinence des réponses.

2.4 Évaluation des LLMs et limites du raisonnement

L'évaluation des performances des LLMs est un champ en pleine structuration. Zhang et al. [9] proposent une synthèse des métriques les plus utilisées : perplexité, exactitude, précision, rappel, F1-score, taux de hallucination, complétude, concision, explicabilité, etc. L'importance de choisir des métriques adaptées à la tâche est soulignée, notamment pour garantir la qualité des systèmes en production. Dans notre projet, nous avons mis en œuvre un panel de métriques (exact match, recall, precision, F1-score, MAE, RMSE) et intégré une évaluation qualitative via « LLM as a judge », conformément aux recommandations de la littérature.

Mirzadeh et al. [6] mettent en évidence les limites des LLMs en matière de raisonnement logique, à travers le benchmark GSM-Symbolic. Leur étude révèle que les modèles actuels privilégient souvent le pattern matching au raisonnement formel, ce qui limite leur robustesse sur des tâches complexes. Cette observation a guidé notre choix d'intégrer des techniques avancées de prompt engineering et de few-shot learning pour améliorer la cohérence et la fiabilité des décisions produites.

De plus, la littérature récente souligne les difficultés des LLMs en matière d'inférence causale et de déduction logique. Selon AgileLoop [7], les LLMs peinent à comprendre les relations de cause à effet et à effectuer des raisonnements structurés, car ils s'appuient principalement sur la reconnaissance de motifs plutôt que sur une véritable compréhension logique. Cette limite est particulièrement critique pour l'automatisation de politiques métier complexes, où la fiabilité du raisonnement est essentielle.

2.5 Few-Shot Learning, décomposition logique et RAG dynamique

Pour pallier les limites des LLMs en raisonnement, la littérature propose le Few-Shot Learning, qui consiste à fournir au modèle quelques exemples structurés pour guider la résolution de tâches nouvelles. Erwin et al. [7] démontrent que la décomposition logique de politiques par prompts few-shot permet d'explicitier la structure logique sous-jacente et d'améliorer la cohérence des décisions. Cette méthode a directement inspiré l'architecture de notre pipeline, où des exemples représentatifs sont intégrés dans le prompt pour renforcer la capacité d'analyse du modèle.

Le RAG dynamique, illustré par Bhattarai et al. [8], constitue une avancée majeure pour enrichir le contexte du modèle en temps réel, en récupérant des exemples ou des documents pertinents depuis une base vectorisée. Leur étude montre que cette approche, combinée au few-shot learning, améliore significativement la robustesse des LLMs sur des tâches de traduction complexe ou d'extraction de règles métier rares. Nous avons implémenté cette méthodologie dans notre projet, en vectorisant les cas passés et en sélectionnant dynamiquement les exemples les plus pertinents pour chaque nouvelle analyse.

2.6 Synthèse et lien avec notre projet

L'état de l'art met en lumière une convergence entre extraction automatisée de règles, intégration de modules explicables, enrichissement dynamique du contexte et évaluation rigoureuse des performances. Notre projet s'inscrit dans cette dynamique :

- En tirant parti des méthodes d'extraction et de structuration des règles métier pour concevoir des entrées et sorties standardisées, facilitant l'automatisation de la prise de décision [1,3].
- En intégrant des techniques avancées de prompt engineering (few-shot, décomposition logique) et de RAG dynamique pour améliorer la robustesse et l'explicabilité des décisions [7,8].
- En évaluant systématiquement les performances via un panel de métriques adaptées et des analyses qualitatives, conformément aux meilleures pratiques du domaine [6,9].
- En adaptant les avancées méthodologiques de la littérature à un cas d'usage concret (politiques bagages aériennes), démontrant la valeur ajoutée des LLMs pour l'automatisation métier [2,4,5].

En conclusion, les travaux scientifiques récents ont directement inspiré la conception de notre pipeline expérimental. Ils ont guidé nos choix méthodologiques, de la structuration des données à l'intégration du raisonnement avancé, en passant par l'évaluation multicritère. Les défis identifiés dans la littérature (fiabilité, explicabilité, adaptation aux cas complexes) restent au cœur de nos perspectives d'évolution, et notre projet contribue à leur résolution par l'expérimentation et l'innovation applicative.

3 Description du travail réalisé


3.1 Correction des incohérences dans les données

Cette tâche d'identification et de correction des incohérences dans les données générées initialement par notre système a constitué une étape cruciale. Elle nécessitait une compréhension approfondie des fichiers clés du projet, notamment `policy.txt` et `generator.py`, afin d'assurer la pertinence et la cohérence de notre processus d'automatisation.

D'un point de vue technique, un examen rigoureux et détaillé du code a permis d'identifier précisément les incohérences présentes. Le fichier `policy.txt` a été entièrement reformulé afin de corriger les incohérences et d'assurer une meilleure lisibilité. Parallèlement, le générateur de données `generator.py` a subi une révision approfondie et une optimisation technique afin d'assurer une génération fiable, régulière et pertinente des cas destinés aux tests futurs.

Cette démarche a abouti à la production d'un livrable stratégique : une base de données propre, harmonisée et directement exploitable, renforçant ainsi la robustesse et la fiabilité des analyses prévues dans les prochaines étapes du projet.

3.2 Méthode batch




La phase dite de « méthode batch » a constitué l'approche initiale de notre projet d'automatisation des politiques bagages à l'aide de modèles de langage de grande taille (LLMs). Elle avait pour objectif d'évaluer la capacité du modèle à analyser massivement un ensemble de cas clients, en intégrant l'ensemble de la politique et les profils passagers dans un seul prompt de grande taille. Ce traitement monolithique a été réalisé durant deux semaines intensives, mobilisant l'ensemble des membres de l'équipe. Il s'agissait d'une étape exploratoire décisive, mise en œuvre afin de tester les capacités de traitement global du modèle Mistral-large.

Sur le plan technique, cette approche correspond à une analyse globale avec contexte intégral. Le modèle recevait en une seule requête le texte complet de la politique (fichier `policy.txt`) ainsi qu'un lot pouvant aller jusqu'à 145 cas de passagers décrits en détail. Le prompt était structuré selon une architecture logique rigoureuse : introduction définissant le rôle du modèle comme expert des politiques bagages, corpus des règles intégralement restitué, présentation séquentielle de chaque profil client et directives de sortie demandant exclusivement un format JSON précis. Ce format attendait pour chaque passager un objet contenant les champs `compliance_result`, `compliance_message`, `fees` et `cargo_items`. Des scripts spécifiques avaient été développés pour injecter ces éléments dans le prompt, envoyer les requêtes, parser les résultats, et détecter les erreurs éventuelles dans les JSON retournés.

Les performances observées au terme de cette étape se sont révélées décevantes. L'approche batch, bien qu'intuitivement séduisante pour son exhaustivité, a rapidement montré ses limites structurelles. Le phénomène de saturation cognitive du modèle s'est traduit par une perte de précision au fil des cas : oubli de la politique, réponses incomplètes ou incohérentes, hallucinations fréquentes, et incapacité à maintenir un format uniforme sur l'ensemble du lot. Les tentatives de parsing échouaient régulièrement à cause de ces réponses bruitées, obligeant à multiplier les essais ou à corriger manuellement les extraits JSON.

Cette expérimentation a tout de même produit un livrable analytique crucial : un rapport détaillé des limites de cette approche globale. Celui-ci recense les erreurs de conformité, les déviations de format, les hallucinations observées, ainsi que l'impossibilité d'obtenir des métriques fiables. Ce rapport a permis de mettre en évidence la nécessité de revoir notre stratégie d'interaction avec le LLM.

3.3 Itératif simple



Après avoir constaté les limites structurelles de l'approche batch, nous avons engagé une deuxième phase dans notre projet : l'itératif simple. Cette méthode s'est imposée comme une réponse adaptée aux contraintes cognitives des modèles de langage, en évitant la surcharge contextuelle liée à l'analyse en masse. Plutôt que de soumettre l'ensemble des cas en une seule requête, chaque profil client a été traité individuellement. Cette approche s'est révélée plus proche d'un usage réaliste, dans lequel un système opérationnel reçoit et traite les demandes une à une.


Le travail s'est déroulé sur deux semaines, au cours desquelles tous les membres de l'équipe ont contribué à l'écriture des scripts, à la mise en place des prompts et à l'analyse des réponses. Dans un premier temps, nous avons développé une version dite "de base", fondée sur un enchaînement simple : pour chaque client, un prompt était généré automatiquement en incluant la politique de bagages, la classe de voyage, l'âge du passager et la liste de ses bagages. Le modèle Mistral-large recevait ces données via un PromptTemplate injecté dans une chaîne LangChain. À chaque itération, trois tentatives étaient autorisées pour assurer une bonne réponse ; les outputs étaient filtrés, parsés, et sauvegardés sous forme de fichiers JSON.

Cette approche a permis d'obtenir un taux d'exploitabilité de 100%, les réponses étant toutes correctement formatées. Les résultats quantitatifs obtenus étaient les suivants :

- Exact Match : 46%
- MAE (Mean Absolute Error) : 69€
- RMSE (Root Mean Square Error) : 111€

Ces performances, bien que largement supérieures à l'approche brute, révélaient encore des difficultés importantes dans l'évaluation précise des frais, avec une dispersion significative des montants calculés par le modèle.

3.4 Itératif FSL




Pour remédier aux difficultés observées dans l'approche itératif simple, nous avons intégré dans une version améliorée un dispositif de Few-Shot Learning (FSL). Cette amélioration consistait à insérer en amont du prompt plusieurs exemples représentatifs, montrant explicitement des cas typiques de conformité, de non-conformité, ou de surcharge. Ces exemples, présentés sous forme d'échanges simulés entre utilisateur et assistant, avaient pour but de guider le modèle vers une compréhension plus précise des attendus, et de renforcer la cohérence des réponses.

Cette stratégie a permis de maintenir une exploitabilité parfaite (100%), avec des réponses mieux structurées et un parsing plus stable. Les résultats quantitatifs obtenus étaient :

- Exact Match : 45%
- MAE : 72€
- RMSE : 114€

Ces performances sont restées relativement similaires à la version de base, avec même une légère dégradation. Cette observation suggère que le modèle avait parfois tendance à reproduire mécaniquement les schémas des exemples fournis, sans toujours les adapter au contexte spécifique de chaque client. En particulier, le modèle semblait parfois "forcer" une structure conforme à celle des exemples, au détriment du raisonnement logique attendu.

3.5 Itératif questions



Fort de l'expérience acquise lors des phases précédentes, nous avons développé une version améliorée de l'approche itérative, que nous avons baptisée "itératif questions". Cette méthode

repose sur une décomposition systématique du raisonnement en plusieurs sous-tâches distinctes, chacune correspondant à une dimension spécifique de l'analyse. L'objectif principal était de réduire la charge cognitive imposée au modèle à chaque itération, tout en améliorant la robustesse et la précision des prédictions.


L'idée fondatrice de cette approche est de fragmenter le prompt global en plusieurs étapes spécialisées : une première analyse des bagages à main (nombre, dimensions, poids, conformité), une seconde consacrée aux bagages enregistrés, une troisième centrée sur l'identification des objets à placer en cargo, et enfin une étape de synthèse pour déterminer la conformité globale et les frais associés. Chaque étape repose sur un prompt dédié, conçu pour traiter uniquement un sous-ensemble de la problématique. Les résultats partiels sont ensuite réinjectés dans les étapes suivantes, ce qui permet au modèle de construire progressivement une réponse cohérente et complète, tout en limitant les risques d'hallucination.

La mise en œuvre technique a nécessité la création d'une classe `LuggageAnalysisPipeline`, intégrant à la fois les prompts spécialisés et la logique de séquençement. Cependant, les résultats obtenus se sont révélés contre-intuitifs :

- Exact Match : 43%
- MAE : 100€
- RMSE : 167€

Cette approche a paradoxalement dégradé les performances par rapport aux versions précédentes, suggérant que la décomposition du raisonnement a introduit une accumulation d'erreurs entre les étapes du pipeline. Cependant cette méthode ayant été introduit tard un ciblage plus précis des questions ou des exemples aurait sans doute conduit à de meilleurs résultats

3.6 RAG et approche hybride



Dans la continuité des méthodes itératives, nous avons exploré une dernière approche combinant raisonnement séquentiel et enrichissement par récupération d'information : le Retrieval-Augmented Generation, ou RAG. Cette méthode consiste à coupler un modèle de langage avec un module de recherche externe, capable d'aller chercher dynamiquement dans une base documentaire les éléments contextuels pertinents, afin de les injecter dans le prompt au moment de l'inférence. L'objectif est double : alléger le prompt initial tout en fournissant au modèle uniquement les informations réellement utiles à la tâche en cours.

Pour mettre en place cette stratégie, nous avons commencé par concevoir un format standardisé de représentation des cas clients, que nous avons appelé "fiches". Chaque fiche reprenait l'ensemble des attributs d'un profil passager de manière structurée : classe de voyage, âge, bagages. Une phase de vectorisation a ensuite été opérée sur l'ensemble du corpus à l'aide de l'encodeur `all-MiniLM-L6-v2`, combinée à une indexation TF-IDF, afin de permettre une recherche efficace par similarité. Ainsi, pour chaque nouveau cas, les exemples les plus proches étaient automatiquement récupérés et intégrés avec leurs colonnes résultats au prompt sous forme d'exemples

contextualisés. A chaque itération le client le plus proche étant supprimé, afin d'éviter de fournir les réponses au LLM et donc une fuite d'informations.

Ce mécanisme a été articulé avec l'approche itératif simple. La base de données d'exemples, enrichie par vectorisation, servait de réservoir pour alimenter dynamiquement le prompt, en adaptant les exemples à la situation analysée. Cette complémentarité entre récupération contextuelle et traitement individuel a permis d'améliorer drastiquement la qualité des prédictions.

Les résultats obtenus avec l'approche RAG ont été exceptionnels :

- Exact Match : 91%
- MAE : 8€
- RMSE : 34€

Ces performances représentent une amélioration considérable par rapport à toutes les approches précédentes, démontrant l'efficacité de l'hybridation entre apprentissage automatique et récupération d'information. L'approche RAG a ainsi constitué le point culminant de notre recherche méthodologique. Un point reste cependant à prendre en compte, l'utilisation de nombreux clients permettant de couvrir quasiment les cas, ce qui explique sûrement ces excellents résultats, un test sur une politique plus complexe semble utile pour les généralisations de la conclusion.

TABLE 1 – Synthèse des performances par approche

Approche	Exact Match	MAE	RMSE	Observations
Batch	N/A	N/A	N/A	Echec complet du parsing
Itératif simple	46%	69€	111€	Baseline fonctionnelle
Itératif FSL	45%	72€	114€	Légère dégradation
Itératif questions	43%	100€	167€	Accumulation d'erreurs
RAG	91%	8€	34€	Performances exceptionnelles

3.7 MÉTRIQUES DE CONFORMITÉ

Accuracy

Exactitude globale des prédictions de conformité (vrai/faux)

- Mesure la proportion de prédictions correctes
- Indicateur général de performance

Precision

Parmi les cas prédits conformes, combien étaient réellement conformes

- Évalue la fiabilité des prédictions positives
- Important pour éviter les faux positifs

Recall

Parmi les cas réellement conformes, combien ont été correctement prédits

- Mesure la capacité à identifier tous les cas conformes
- Critique pour ne pas manquer de cas conformes

F1-Score

Moyenne harmonique de la précision et du rappel

- Équilibre entre précision et rappel
- Métrique de synthèse

Matrice de Confusion

Répartition des Vrais/Faux Positifs et Négatifs

- Vision détaillée des types d'erreurs
- Aide au diagnostic des problèmes

3.8 MÉTRIQUES D'ESTIMATION DES FRAIS

Exact Match

Pourcentage de montants de frais parfaitement prédits

- Précision absolue sur les montants
- Standard de référence strict

Dans les 5/10

Précision basée sur la tolérance pour l'estimation pratique des frais

- Tolérance d'erreur acceptable en contexte commercial
- Indicateurs pragmatiques

MAE (Erreur Absolue Moyenne)

Différence absolue moyenne en euros

- Mesure l'erreur moyenne en valeur absolue
- Interprétation directe en euros

RMSE (Erreur Quadratique Moyenne)

Pénalise davantage les erreurs importantes

- Sensible aux erreurs importantes
- Indicateur de stabilité

MAPE (Erreur Absolue Moyenne en %)

Erreur relative en pourcentage

- Erreur relative indépendante de l'échelle
- Comparaison entre différents montants

3.9 MÉTRIQUES D'IDENTIFICATION CARGO

Precision

Objets cargo correctement identifiés vs. tous les objets cargo prédits

- Fiabilité de l'identification des types de bagages
- Évite les sur-classifications

Recall

Objets cargo correctement identifiés vs. tous les objets cargo réels

- Capacité à identifier tous les types présents
- Évite les sous-classifications

F1-Score

Équilibre entre précision et rappel pour l'identification cargo

- Synthèse des performances d'identification
- Optimisation globale

Score de Jaccard

Intersection sur union, mesure la similarité d'ensembles

- Métrique spécialisée pour la comparaison d'ensembles
- Particulièrement adaptée aux listes de cargo

3.10 MÉTRIQUES DE MESSAGES DE CONFORMITÉ

Taux de Couverture

Dans quelle mesure les messages prédits couvrent les raisons de conformité attendues

- Évaluation sémantique des explications
- Vérification de la complétude

LLM-as-a-Judge

Utilise un LLM pour évaluer la similarité sémantique et la couverture des raisons

- Analyse intelligente du contenu textuel
- Accepte les différentes formulations
- Tolère les explications supplémentaires




TABLE 2 – Synthèse des tâches du projet

Tâche	Durée	Participants	Resp.	Livrable
Correction incohérences	2 sem.	Tous	Romain	BDD corrigée & documentation
Batch	1 mois	Tous	Titouan Omar	Rapport d'échec & enseignements
Itératif simple	2 mois	Tous	Titouan Romain	Exact match : 46% MAE : 69€ RMSE : 111€
Itératif FSL	2 mois	Titouan	Romain	Exact match : 45% MAE : 72€ RMSE : 114€
Itératif questions	2 sem.	Romain	Titouan	Exact match : 43% MAE : 100€ RMSE : 167€
RAG	3 mois	Tous	Claudia	Exact match : 91% MAE : 8€ RMSE : 34€
Métriques & LLM as judge	2 sem	Tous	Claudia Ahmed	Framework d'évaluation complet

4 Conclusion

Ce projet d'automatisation des politiques métier à l'aide de grands modèles de langage (LLMs) a constitué une expérience enrichissante et formatrice, tant sur le plan technique que méthodologique. Il nous a permis de confronter les capacités actuelles de l'intelligence artificielle générative à une problématique concrète et complexe : l'application rigoureuse et fiable de règles métier issues de politiques bagages aériennes.

En prenant du recul, il apparaît que la principale difficulté réside dans la capacité des LLMs à raisonner de façon logique et cohérente, au-delà d'une simple reconnaissance statistique des motifs. Nos expérimentations ont montré que des approches naïves, fondées sur un traitement global et monolithique, peinent à fournir des résultats exploitables en raison de la surcharge cognitive imposée au modèle. À l'inverse, l'approche RAG, associant récupération d'exemples pertinents et traitement individuel, améliore drastiquement la précision et la robustesse des prédictions avec un exact match de 91%. Ces résultats soulignent l'importance d'un design réfléchi du pipeline d'analyse, qui adapte la méthodologie aux capacités intrinsèques du modèle. Conclusion basée sur les résultats d'une politique donc prometteuse mais à étudier sur des politiques plus complexes.

Paradoxalement, notre approche de décomposition modulaire (itératif questions) a dégradé les performances par rapport à l'itération simple, révélant que la fragmentation excessive du raisonnement peut introduire une accumulation d'erreurs entre les étapes. Cette observation met en lumière la complexité de l'optimisation des systèmes LLM, où l'intuition humaine ne prédit pas toujours les meilleurs résultats. Cette conclusion pouvant être réfutée comme énoncé plus haut avec un approfondissement de cette méthode

La valeur ajoutée de notre projet pour le client, IBM France Lab, réside principalement dans la démonstration de la faisabilité d'une automatisation partielle des décisions métiers via LLMs, avec des niveaux de performance prometteurs. Nous avons pu identifier des leviers d'amélioration clairs, ainsi que des limitations actuelles à surmonter, notamment en ce qui concerne l'interprétation fine des règles tarifaires et la gestion des cas complexes. Par ailleurs, notre démarche a renforcé la capacité du laboratoire à concevoir des systèmes hybrides associant apprentissage automatique et récupération documentaire, une voie prometteuse pour l'industrialisation de ces technologies.

Plusieurs perspectives peuvent être envisagées pour approfondir et compléter ce travail. D'une part, l'intégration de techniques d'explicabilité plus poussées pourrait améliorer la confiance des utilisateurs dans les décisions automatiques, notamment dans des secteurs sensibles. D'autre part, l'extension du pipeline à d'autres types de politiques métier, avec des règles encore plus complexes ou évolutives, permettrait de tester la robustesse et la généralisabilité de la méthode. Enfin, un travail de calibration fine des paramètres de récupération d'exemples et d'optimisation des prompts, potentiellement assisté par un apprentissage par renforcement, offrirait une voie pour améliorer encore la précision et la stabilité du système.

En somme, ce projet a constitué une étape clé dans la compréhension des enjeux liés à l'usage des LLMs pour l'automatisation décisionnelle. Il ouvre la voie à des développements futurs combinant intelligence artificielle, ingénierie logicielle et sciences des données, avec pour objectif d'accompagner les entreprises dans leur transformation numérique grâce à des outils plus intelligents, adaptatifs et explicables.

5 Bibliographie

Références

- [1] Miskell et al., *Automated Framework to Extract Software Requirements from Source Code*, 2023. <https://dl.acm.org/doi/pdf/10.1145/3639233.3639242>
- [2] Raikov et al., *Editorial : Large language models in work and business*, 2024. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11638215/>
- [3] Bernardi et al., *A preliminary study on Business Process-aware Large Language Models*, 2024. <https://ceur-ws.org/Vol-3762/504.pdf>
- [4] Equipe de doctorants de l'Institut Stevens de technologie, *Applying Large Language Models to Financial Decision-Making*, 2024. <https://www.stevens.edu/news/applying-large-language-models-to-financial-decision-making>
- [5] Ugarte, *What's an LLM and How Do LLMs Work?*, Appsmith, 2024. <https://www.appsmith.com/blog/what-is-llm>
- [6] Mirzadeh et al., *GSM-Symbolic : Understanding the Limitations of Mathematical Reasoning in Large Language Models*, 2024. <https://arxiv.org/pdf/2410.05229>
- [7] Erwin et al., *Logical Decomposition of Policies with Few-Shot Prompting*, 2024. <https://arxiv.org/html/2501.11335>
- [8] Bhattarai et al., *Dynamic Retrieval-Augmented Generation for Improving Few-Shot Prompting in Code Translation*, 2024. <https://arxiv.org/abs/2407.19619>
- [9] Zhang et al., *A Comprehensive Survey on Evaluation Metrics of Large Language Models*, 2024. <https://arxiv.org/abs/2310.19736>